

1. Conocimientos previos


1.1 Redes neuronales

Una **red neuronal** es un modelo computacional inspirado en la forma de procesar información de las neuronas del cerebro. Las redes neuronales han generado una significativa cantidad de investigación e industria gracias a sus resultados en reconocimiento del habla, visión por computador y procesamiento de texto. Para dejar claro su funcionamiento explicaré primero el funcionamiento de una sola neurona, para después unirlo con la organización por capas de varias neuronas y finalmente explicar el algoritmo de *backpropagation*.

1.1.1 Una neurona

Definición 1.1. La unidad de computación básica de una red neuronal es una **neurona**, también llamada nodo o unidad. Su función es recibir una entrada desde otros nodos y calcular una salida.

Cada entrada (x) tiene asociado un peso, que es asignado en base a su importancia relativa a otras entradas. La neurona aplica una función (f) a la suma ponderada de las entradas como muestra la figura:



Además de los elementos ya comentados tendremos un término de sesgo (b), cuyo objetivo es proveer cada nodo con un valor entrenable que no dependa de la entrada.


La salida de la neurona (Y) se calcula de la siguiente manera:

$$Y = f \left(\sum_i \omega_i x_i + b \right)$$


Llamaremos a f la **función de activación**, es una función (no lineal) cuyo propósito es introducir no linealidad a la salida de la neurona. Ésto ayuda a adaptar mejor el modelo a problemas reales, puesto a que estos raramente son lineales.

Las funciones de activación más utilizadas son:


- Sigmoide: $f(x) = \frac{1}{1+e^{-x}}$



■ Tanh: $f(x) = \frac{2}{1+e^{-2x}} - 1$




■ ReLU: $f(x) = \max(0, x)$



Dotando una neurona de una función de pérdida en la salida podríamos convertirla en un clasificador lineal, pero la verdadera potencia del método viene dada al unir diversas neuronas en lo que llamaremos capas.

1.1 Organización por capas

Las redes neuronales se modelizan como una colección de neuronas conectadas en un grafo acíclico, comúnmente organizado por capas. El tipo más común de capa es la capa completa (*fully-connected layer*), en el que todas las neuronas de dos capas consecutivas están conectadas entre ellas, mientras que no comparten ninguna conexión con las de su propia capa, como muestra la figura. Si tenemos diversas capas ocultas diremos que se trata de una red profunda (*deep network*).



La red neuronal más básica la podemos dividir en:

1. Nodos de entrada: Proveen la red de información del exterior, todo su conjunto se conoce como la capa de entrada.
2. Nodos ocultos: Los nodos ocultos no tienen conexión directa con el exterior. Solo calculan y transfieren información de la entrada a la salida. La colección de los nodos ocultos se denomina las capas ocultas.
3. Nodos de salida: Colectivamente denominados nodos de salida y son responsables de la computación y transferencia de información al exterior.

1.1 Entrenar la red: Backpropagation

Finalmente, queda explicar como entrenar los distintos parámetros para que se adapten a los datos, para ello se utiliza **backpropagation**.

El algoritmo de backpropagation empieza con un *forward pass* (una evaluación de los datos utilizando toda la red) por toda la red, la predicción dada por la red se compara con la salida esperada y se calcula un error utilizando la función de pérdida (por ejemplo la de mínimos cuadrados). La pérdida calculada se utiliza para actualizar los pesos de la última capa, buscando los valores de éstos que la minimizan.

La complejidad reside en optimizar los pesos de las capas que no están conectadas directamente con la salida. Para resolver esto backpropagation utiliza la regla de la cadena, que permite calcular derivadas de capas previas, y de esta forma actualizar los pesos de las capas restantes.

Tradicionalmente, el cambio de pesos se ha computado usando el algoritmo de optimización llamado *Stochastic Gradient Descent*, un método iterativo de minimización.

De esta forma, aplicando backpropagation iterativamente podemos estimar los pesos de todas las capas de una red neuronal para un problema dado.

1.2 Redes convolucionales

Definición 1.2. Una **red convolucional** es una secuencia de capas de diferentes tipos con al menos una de las capas es una capa convolucional donde cada capa transforma un volumen de activaciones en otro a través de una función diferenciable.

Las redes convolucionales son muy similares a las redes neuronales explicadas, las mayores diferencias son que contienen un tipo especial de neuronas (las neuronas convolucionales) y que asume explícitamente que la entrada son datos con una estructura concreta (como por ejemplo imágenes), lo que permite añadir ciertas propiedades a la arquitectura. Esto permite hacer un *forward pass* más eficiente de implementar y reducir significativamente la cantidad de parámetros, (nótese que cuantos más parámetros tenga una red, mayor subconjunto de datos de entrenamiento necesitamos para evitar tener sobre-ajuste).

Una neurona convolucional es aquella que opera con una convolución[4].

Definición 1.3. Una **convolución** es una aplicación matemática cuya entrada son dos funciones de valores reales (x y w) y cuya salida es otra función (s).

Usualmente se denota como $s(t) = (x * w)(t)$.

En el contexto de redes convolucionales llamaremos a x *entrada*, a w *kernel* y a la salida *mapa de características*.

Nótese que la definición no depende de la dimensión del espacio, es decir, que podemos definir una convolución para tantas dimensiones como necesitemos. En el caso concreto de una imagen I (de dos dimensiones) y un kernel K , la convolución quedaría como:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) K(m, n)$$

Típicamente las neuronas convolucionales tienen una entrada limitada, es decir están conectadas solo a un subconjunto de las neuronas de la capa anterior. En contraste, las neuronas de una capa completa están conectadas a todas las neuronas de la capa anterior. De esta forma se reducen la cantidad de parámetros de la red.

Por su conectividad limitada, las capas convolucionales pueden centrarse en una parcela particular de la entrada. El conjunto de pesos (que sería equivalente al kernel comentado en la definición 2.3) aprendido por esta parcela puede ser relevante para las otras parcelas de la entrada, por tanto, podemos definir neuronas similares que utilicen el mismo kernel, pero que se enfoquen en otra parte de la entrada. Esta idea se conoce como "weight sharing", por que varias neuronas de la misma capa están definidas por un conjunto común de pesos, esto permite tener una considerable cantidad de neuronas utilizando los mismos parámetros. Esto puede ayudar a detectar los mismos patrones en diferentes partes de la entrada. Por ejemplo si tenemos una neurona que detecta ojos, al pasarla por una foto con una cara se activará dos veces.





Figura 1: Ejemplo de la forma de operar una convolución sobre una imagen.

En la figura 2.2 podemos ver un ejemplo del funcionamiento de una convolución con un kernel de tamaño 9 sobre una imagen, en el ejemplo podemos observar como se comparten los pesos a la hora de calcular el resultado.

Finalmente queda comentar los tipos de capa más comunes en una red convolucional:

- Capa convolucional, capas formadas por neuronas convolucionales, la mayoría de capas de una red convolucional serán de este tipo.
- Capa completa, es una capa donde todas las neuronas están conectadas entre ellas. Se suele utilizar como capa de clasificación.
- *Pooling Layer*, consiste en una capa que aplica una reducción matemática a su input (como una media o un max). El objetivo es facilitar a la red que reconozca datos que están relacionados en un sentido espacial (imágenes equivalentes en diferentes posiciones), además reducen el tamaño de la salida de la capa, lo que provoca una reducción de la complejidad de la red.



1.3 Transfer Learning

En la práctica pocas personas entrenan una red profunda desde cero (con inicialización aleatoria), puesto a que tienen unos requisitos bastante exigentes a la hora de entrenarla, los mayores problemas que puedes encontrar son:

1. A causa de la gran cantidad de parámetros a entrenar que tiene una red profunda necesitas un **conjunto de datos de gran tamaño**.
2. El **coste computacional** de entrenar la red.
3. La búsqueda de **hiper-parámetros** (valores de los que depende el modelo) óptimos, los modelos que tienen hiper-parámetros necesitan datos adicionales para calcularlos y entrenar varias veces el modelo inicial, por tanto incrementa los problemas 1 y 2.

Por tanto, es común pre-entrenar una red convolucional en un conjunto de datos significativamente grande y usar la red convolucional como inicialización o como extractor fijo de características de la tarea de interés.

Los dos casos más comunes de transfer learning son:

- **Fine-tuning** La primera estrategia consiste en inicializar los datos desde un estado no aleatorio (tomando los pesos ya entrenados). De esta manera puedes reducir significativamente el conjunto de datos necesario para entrenarla, sin embargo, sigue necesitando tiempo para optimizar los múltiples hiper-parámetros involucrados en el proceso y una cantidad significativa de recursos computacionales.
- **Extracción de características** (o Feature Extraction) Consiste en procesar un conjunto de datos a través de una red neuronal ya entrenada y extraer valores de activación para que puedan ser utilizados por otro mecanismo de aprendizaje. Este método es aplicable a conjuntos de datos de cualquier tamaño, puesto a que cada dato es procesado independientemente. Además tiene un menor coste computacional, ya que no tiene que entrenar la red y no requiere la optimización de hiper-parámetros. Por estos motivos las aplicaciones de *transfer learning for feature extraction* están limitadas solo a las capacidades de los métodos que utilices encima de la representación profunda obtenida.

En nuestro caso nos centraremos en *transfer learning for features extraction*.

2. Trabajo Relacionado

2.1 Full-Network embedding

En general en *transfer learning for feature extraction* es común tomar los valores de activación de una sola capa cercana a la salida, como podemos ver en la figura 3.1. El resto de capas se descartan por "ser poco probable que contengan una representación mejor", sin embargo es conocido que todas las capas de una red profunda pueden contribuir a caracterizar los datos de diferentes maneras. Esto implica que la representación más versátil y rica que puede ser generada por un proceso de extracción de características debe incluir todas las capas de la red, es decir, debe definir un *full-network embedding*.





Figura 2: Estructura básica que se suele utilizar en *feature extraction*

Dado un conjunto de datos $t1$, queremos representarlo en el lenguaje aprendido para una tarea $t0$. Para ello el *full-network embedding* se divide en 4 pasos:

- El primer paso es hacer un **forward pass** de cada instancia de datos de $t1$ a través del modelo entrenado en $t0$, guardando todos los valores de activación de cada capa de la red, (tanto las convolucionales como las completas).
- El segundo paso consiste en un **spatial average pooling** en los filtros convolucionales. Como se ha explicado en el capítulo sobre redes convolucionales, un filtro convolucional genera varias activaciones para una entrada, para darle la capacidad de obtener información espacial. El objetivo de este paso es obtener un solo valor de activación para cada filtro, evitando así un aumento de la dimensionalidad. Los valores resultantes se concatenan a los de las capas completas en un solo vector, para generar el *embedding* completo.
- El tercer paso es una **estandarización de características**. Puesto a que los valores del *embedding* provienen de distintos tipos de neuronas en distintos puntos de la red hace falta una estandarización. El valor estandarizado de cada categoría se obtiene calculando la media y la desviación típica del conjunto de datos de entrenamiento. De esta forma se pueden integrar los distintos valores en el *embedding*.
- Finalmente se aplica una **discretización de características** para evitar problemas al intentar explorar un espacio de dimensión tan grande. Ésta discretización consiste en tomar unos límites que dependen de los datos, ft^- y ft^+ y reemplazar los valores que tienen un valor atípicamente bajo (todos los



valores $x < ft^-$) por un -1, los que tienen un valor típico (todos los valores $ft^- < x < ft^+$) por un 0 y los que tienen un valor atípicamente alto (todos los valores $ft^+ < x$) por un 1, como podemos ver en la representación gráfica 3.1. Para encontrar los límites se basan en [6], donde dan una visión estadística sobre como evaluar la importancia de las diferentes características de una red convolucional comparando las activaciones para una clase concreta respecto al resto de clases del conjunto de datos. De esta forma los autores de [6] separan las características en tres conjuntos: *característico por presencia*, *no característico* y *característico por ausencia*.




Figura 3: Estructura del *full-network embedding*

2.2 Wordnet

Wordnet es una base de datos que contiene nombres, verbos, adjetivos y adverbios en conjuntos de sinónimos (que llamaremos *synsets*). Los *synsets* están conectados entre ellos por medio de relaciones conceptuales, semánticas y léxicas. Utilizando los *synsets* y sus relaciones, se puede generar un grafo que puede ser utilizado para distintos objetivos, como lingüística computacional y procesamiento del lenguaje natural.

En concreto utilizaremos las relaciones de:

- **Sinonimia** : dos palabras son sinónimos si tienen el mismo significado (ej, gato y minino).

- **Hiponimia:** una palabra es hipónimo de otra si su significado es más específico que el de ésta (ej, silla es hipónimo de mueble).
- **Hipernimia:** una palabra es hiperónimo de otra si su significado es menos específico que el de ésta (ej, perro es hiperónimo de dalmata).




Figura 4: Ejemplo de hipónimos

2.3 Imagenet

Imagenet es una base de datos de imágenes organizada utilizando la jerarquía de *wordnet*. Su principal objetivo es dotar a los investigadores en campos relacionados con visión artificial de una base de datos a gran escala con la que poder trabajar. Actualmente consta de 14,197,122 imágenes y 21841 *synsets* indexados.

Para el full-network embedding utilizaron el subconjunto correspondiente al reto de *imagenet* de 2012 de reconocimiento de imágenes.

Éste consta de:

- Un conjunto de datos de entrenamiento de 1.2 millones de muestras y 1000 categorías diferentes.
- Un conjunto de datos de validación de 50000 muestras y 1000 categorías.

Entre las posibles categorías podemos encontrar *synsets* de diferentes niveles de especificación, por ejemplo tenemos las categorías: perro, dalmata, pastor alemán...